

שינויים בקוד:

1. שינוי היפר פרמטרים:

1.ה- `BUFFER_CAPACITY = 300` — **קטן מדי**, מאגר גדול יותר מאפשר לסוכן ללמוד מפיזור רחב יותר של חוויות עבר, ובכך מפחית סכנה של overfitting לאירועים האחרונים. ערך ששינינו אליו: 150000

2.ה- `TOTAL_EPISODES = 100` — **לא מספיק** לפי תוצאות מניסויים, סביבת lunarlander vht היא מורכבת, דורש בדרך כלל 400–1000 אפיזודות לפחות כדי להתכנס. עם 100 אפיזודות האימון פשוט נגמר לפני שהסוכן "הספיק ללמוד". ערך ששינינו אליו: 1000

3.ה- `GAMMA = 0.90` — **נמוך מדי** ערך נמוך גורם לסוכן להתמקד בתגמול המיידי ולהתעלם מהשלכות עתידיות. נחיתה רכה דורשת תכנון לטווח ארוך. ערך ששינינו אליו: 0.99.

4.ה- `UPDATE_TARGET = 5` — **עדכון תכוף מדי של רשת המטרה** כשהרשת המקוונת עדיין "רועשת" ולא מדויקת, עדכון תכוף של ה-target מייצר יעדי למידה לא יציבים. ערך מומלץ: 100–500. ערך ששינינו אליו: 500.

5.ה- `EPSILON_DECAY = 0.98` — **דועך מהר מדי**. עם 100 אפיזודות עבד טוב, אבל עם 600 אפיזודות הסוכן יגיע ל-`EPSILON_MIN` מוקדם מדי ויפסיק לחקור לפני שבאמת למד. ערך ששינינו אליו: 0.997.

6.ה- **Learning Rate (LR) – הופחת מ- $5e-4$ ל- $1e-4$** קצב למידה נמוך יותר מספק עדכונים יציבים יותר ומונע את תנודות התגמול ה"מזגזגות" שנצפו בהרצות אימון ראשונות שביצענו.

7.ה- **BATCH-SIZE הוגדל ל-128**: משפר דיוק — גרדיאנט מחושב על יותר דוגמאות = עדכון יציב יותר.

2. שיפור ארכיטקטורת רשת נוירונים:

1. הרחבת הרשת: `256 → 128`

הרשת המקורית צרה מדי — 128 נוירונים מגבילים את יכולת הרשת לייצג מצבים מורכבים. LunarLander מחזיר 8 ערכי state (מיקום, מהירות, זווית, מגע קרקע וכו') והרשת צריכה ללמוד קשרים מורכבים ביניהם. הרחבה ל-256 נותנת לרשת יותר יכולת חשיבה, הרשת לומדת ייצוגים שונים בשכבות הראשונות ומצמצמת למידע המהותי בסוף.

שינויים שנוסו ולא עבדו:

1. הוספת `LayerNorm`

בלי נורמליזציה, יהיה מצב שינוי לא אחיד בערכים שעוברים בין שכבות מה שיכול להאט את הלמידה. `LayerNorm` מנרמל את הפלט של כל שכבה לפני שהוא עובר הלאה — שומר על ערכים יציבים לאורך כל הרשת.

2. החלפת `ReLU` ב-`SiLU`

עבור נורונים שקטנים מ-0, relu יחזיר 0 כך שהם לא יתרמו ללמידה

$$f(x) = \max(0, x)$$

עבור silu, משתמשים בפונקציית sigmoid כך שיתקבל ערך קטן אך לא אפסי, כל הנורונים ממשיכים ללמוד

$$f(x) = x * \text{sigmoid}(x)$$

2. שימוש ב-GRADIENT-CLIPPING

1. גרדיאנטים גדולים מדי עלולים לגרום לעדכוני משקל קיצוניים שגורמים לחוסר יציבות. חיתוך גרדיאנט שומר על האימון יציב ומאפשר שיעורי למידה גדולים יותר.

3.